

ED- Christel Vrain

Alexandre Masson

14 Janvier 2013

Table des matières

1	Motivation	3
2	Langage R	4
3	Compléments sur R	6
3.1	Un peu de terminologie	6
4	Graphique sous R	7
5	Rappels de probabilité	9
5.1	Notion de base	9
5.2	20 Février 2013	10
5.3	Variable aléatoire continue	11
6	6 Mars 2013	11
7	13 Mars 2013	12
7.1	Analyse de régression	12

les TDs sont en anglais.

1 Motivation

Plein de données, expansion de l'univers digital. différentes étapes :

- statistique descriptive
- Régression : analyser la relation d'une var vec d'autres
- Fouille de données : Classification supervisée ou non, prédiction , recherche de motifs fréquents.

univ lyon enseignements R

2 Langage R

Langage et environnement pour le calcul statistique et les graphiques.
il tes libre.

commande de bases Affectation `-> u <-` ou `assign("x",valeur)`.

Des Variables : pas de chiffre ou caractère spécial en premier dans le nom, sensible à la casse, certains noms sont déjà pris.

structure de données : vecteur numérique la structure élémentaire est `i`, vecteur, un nombre est un vecteur, on affecte a une variable un vecteur, avec l'opérateur `c(...)` en mettant dans `c`, le contenu du vecteur. l'opérateur `[]` donne l'élément du tableau, on peut passer à `[]` un vecteur de données, il renvoi les valeurs placées à tous les index présents dans le tableau entre `[]`.

Arithmétique vectorielle toutes les opérations telles que `sin`, et `cos`, sont appliquées point à point sur tous les variables d'un vecteur. les tableaux sont indexés de 1 à N. la fonction `sort(vecteur)` est implémentée, ainsi que `min` et `max`, et `range`, `length`, `sum`, `prod`, `mean`.

NaN signifie not a number.

Vecteur Logique les valeurs sont `TRUE`,`FALSE`,`NA`(not available). Nous avons a disposition des opérateurs logiques tels que `<`, `<=`, `>`, `>=`, `==`, `!=`. nous avons aussi `c1&c2`, `c1|c2` et `!c1`. `is.na()` teste si X est NA ou NAN, `is.nan(x)` teste uniquement le nan.

Vecteur de caractères les valeurs d'un vecteur doivent etre de meme type : `logical`, `numéric`, `complex`, `character` (ou `raw`). la fonction `mode(x)` renvoie le type des valeurs présentent dans `x`. on utilise `as.character(x)` pour transformer les valeurs de `x` en `characters`.

Index des vecteurs un vecteur, l'opérateur `x:y` construit un vecteur remplis avec toutes les valeurs entre `x` et `y`. l'opérateur `-` sur un vecteur renvoie le complémentaire du vecteur. il est possible avec `names(vecteur) <- c("chaîne", "chaîne2",...]` pour nommer les index des tableaux.

Séquences fonction `seq` avec au plus 5 arguments :

- `from =`
- `to =`
- `by =`
- `length =`
- `along = vecteur`(seul argument si utilisé, créer une séquence de 1 à `length(vecteur)`).

Factor Utilisé pour étiqueter les données de vecteurs de même longueur., il est ensuite possible d'effectuer des opérations en discriminant les valeurs par les étiquettes., `tapply` permet d'appliquer une fonction (3em param) sur un vecteur (1er param), en utilisant les étiquettes un vecteur d'étiquettes (2nd param).

Fonctions définies de la forme `nom <- fonction(arg1,...,argn)`. les instructions sont séparées par des `;`. On a aussi accès aux conditionnelles, et au boucle, mais il faut éviter les boucles, les boucles `for`, `repeat`, `while(condition) expr`, et le `break` pour terminer les boucles.

Tableau - Matrices Un vecteur peut être utilisé comme un tableau à plusieurs dimensions si on lui associe un vecteur de dimension. La fonction `dim(vect) <- c(x,y)`; `vect`, transforme le vecteur en tableau de lignes et de `y` colonnes, il remplit ensuite le tableau avec les données du vecteur, en remplissant la première colonne avec autant de valeurs que de lignes, puis la seconde colonne avec la suite, etc...

Tableaux d'indices il peut être construit par la fonction `array(vecteur, dimension)`. on a aussi des opérations sur les matrices, soient `a` et `b` deux matrices et `f` une fonction `n` alors `outer` applique la fonction et renvoie une matrice de taille la concaténation des tailles des deux vecteurs.

Listes Collection ordonnée d'objets, appelés composants. Un composant peut être désigné par :

- son numéro : `Liste [[x]]`
- un nom : `List $name`
- ATTENTION : `List[i :J]` retourne une sous liste (avec les noms des composants).

Les listes sont extensibles, il est possible de rajouter des champs en mettant : `List$nomChamp<-valeur`.

Data frame c'est comme une matrice mais avec des modes et attributs différents, les chaînes de caractères sont transformées en facteurs.

Lecture des fichiers première ligne doit avoir une chaîne de caractère par attribut du dataframe, tout le reste est ensuite lu comme attribut, mais les chaînes sont considérées comme facteur.

Réseau de neurones Introduit dans les 60's. Les observations sont décrites par n variables et une étiquette 1,1 ou 0,1. Les entrées sont reliées au neurones avec des poids, et l'étiquette c'est le produit scalaire des entrées et des poids, et si elle est plus grande qu'un poids on retourne un sinon zéro. Le neurone sépare donc l'espace en deux demi plan, un ou c'est vrai et un ou c'est faux. on note O pour output. Le perceptron est donc un ensemble de neurones qui sont connectés et où les sorties de neurones sont les entrées d'autres neurones.

Apprendre le perceptron c'est apprendre les poids, on constate que les poids et le seuil ne sont pas du même côté de l'équation, on remplace le b par une entrée x_0 toujours égale à 1, et un poids w_0 qui devra être égale à b .

apprentissage par correction d'erreurs

```
Entrées : un ensemble d'exemples  $S$  de  $\mathbb{R}^n \times \{0,1\}$ 
Sortie :  $P$  un perceptron défini par  $(w_0, w_1, \dots, w_n)$ 
Initialiser aléatoirement les poids  $w_i$ 
Repeter{
  Pour tout exemple  $(x_1, x_2, \dots, x_n)$  dans  $S$ 
  calculer la sortie  $o$ 
  pour tout  $i$ ,  $w_i \leftarrow w_i + (c - o)x_i$ 
}
jusqu'à convergence }
```

Première question : converge-t-il ? il a été montré que si les exemples sont linéairement séparable, il existe donc un hyperplan, il va le trouver. Dans la pratique, on va limiter le nombre de répétition des tours de boucle.

2 critiques pour cet algorithme :

- : algorithme ne converge que si les données sont linéairement séparables. Donc il converge s'il doit converger.
- : pas de garantie sur la droite que l'on trouve, pas de distance maximum.
- Cet algorithme s'appelle algorithme par descente de gradient.

3 Compléments sur R

3.1 Un peu de terminologie

- Population : ensemble d'éléments sur lesquels se porte l'analyse
- individu : élément de la population
- variable : sert à décrire la population
- modalité d'une variable : valeur de la variable

plot `plot(x,y)`, ou `plot(u)` avec liste de vecteur, ou matrice 2D.

variables qualitatives Soucis de commit, penser à regarder le pdf graphique sous R.

4 Graphique sous R

6 Février 2013

Continuons la partie représentation summary nous donne des infos sur une dataframe telles que le min, le 1st.quarter, la median, la mean, le 3rd. Quarter ainsi que le max. Faire attention, car le choix de découpage influe beaucoup sur la perception, et peut donner une fausse interprétation. faire plusieurs diagramme pour voir les données sous différents angles.

Regarder d'un œil critique

- Mesures de tendances centrales ; moyenne, médiane, etc...

-

Peut être un cours de rappel de proba pas des proba pour faire des probas, mais par exemple revoir les lois gaussienne car on utilise des échantillons gaussiens

Propriété de la moyenne Toutes les observations ont le même poids : les valeurs extrêmes influencent autant que les autres.

Aussi la somme des écarts à la moyenne est nulle $\sum(x_i - \text{mean}(x)) = 0$.

La somme des carrés des distances à la moyenne est plus faible que la somme des carrés des distances à toute autre valeur.

-> la moyenne est la mesure qui minimise la somme des carrés des écarts à elle-même.

autres moyennes

- moyenne géométrique : racine n_{ieme} du produit des n facteurs : $x_1 * x_2 * \dots * x_n$
- moyenne géométrique pondérée racine k_{ieme} des x_n^k
- moyenne harmonique : k éléments, divisé par la somme des $1/x^k$
- moyenne quadratique : $Q = \sqrt{1/k(x_1^2 + x_2^2 + \dots + x_n^2)}$

Toutes ces moyennes se généralisent en : le nombre M tel que

$$f(M) = 1/n * (n_1 \cdot f(x_1) + \dots + n_n \cdot f(x_n))$$

Médiane point qui partage la distribution d'une série d'observations en deux parts égales -> partage l'histogramme(densité) en deux parties de surface égales. Ne s'applique que pour des observations pouvant être ordonnées.

Minimise la somme des distances absolues de toutes les observations à ce point.

Estimation Classement des observations par ordre croissant

Calcul : si le nombre d'observations est impair, la médiane est la $(k+1)/2$ valeur

Si c'est paire, toute observation entre $k/2$ et $(k/2)+1$, ou la moyenne des observations $k/2$ et $(k/2)+1$.

si les observations sont regroupées par classe, une valeur plus précise sous l'hypothèse d'une répartition uniforme des observations.

Mode Valeur qui possède la fréquence la plus élevée
 n'est pas toujours une valeur centrale de la distribution
 une distribution peut avoir plusieurs modes, unimodale, bimodale, asymétrique...

Comparaison

- moyenne : tiens compte des valeurs de la distribution
- mode : indique une seule valeur de la distribution
- médiane : indique un rang
- si la distribution est unimodale et symétrique, moyenne , mode, et médiane sont confondus.
- Si la distribution est bimodale et symétrique, moyenne et médiane sont confondus.
- si la distribution est asymétrique, ils peuvent avoir des valeurs différentes.
 - tirée à droite, mode, puis médiane , puis moyenne
 - tirée à gauche : moyenne , médiane, mode

Variance Elle donne la répartition des valeurs autour de la moyenne, si elle est faible, l'ensemble des valeurs est proche de la moyenne, sinon, cela nous indique que la moyenne c'est pas représentative des valeurs des observations.

Propriété

la variance est toujours positive
 si elle est nulle , toutes les observations sont identiques,
 si on ajoute la même constante à toutes les observations, alors la moyenne change, mais pas la variance.
 si on multiplie les observations par une même constante positive ou négative, on modifie la variance à un facteur multiplicatif (le carré de la constante, vu que la variance fait un carré)

Autre façons de calculer la variance variable quantitative avec k observations, $x_1, \dots, x_n = 1/k \sum (x_i^2 - mean(x)^2)$ Différence entre var de R ,et la vraie variance, car R se base sur un échantillon pour trouver la moyenne pour effectuer son calcul. On parle d'estimateur sans biais, si quand on change d'échantillon, on retrouve la même valeur qu'avec toute la population, donc la variance ne l'est pas.

Autres mesures écart moyen : prend la valeur absolue plutôt que le carré
 écart médian : prend la médiane au lieu de la moyenne pour le calcul de variance.
 intervalle interquartile :

- Intervalle comprenant 50 % des observations le plus au ventre de la distribution.
- Se définit à partir des quantiles qui sont des positions particulières (ex : médiane)
- quartile : coupe en quatre, déciles : amis en 10, centiles : idem mais en 100.

- IQR : intervalle inter quantile : il fait la différence entre le 75% et le 25%

Dispersion pour les variables qualitatives

- variables dichotomique : même définitions que pour les variables qualitatives
- variable multicatégorielles : $\sigma^2(X) = p_1 * \dots * p_j$ ou p_i est la proportion d'apparition de la classe.

Coefficient de Pearson 13 février 2013

Moment d'ordre r, en langage R $sum[(x - mean(x))^3]/length(x)]^2$

mesures d'aplatissement coefficient de Pearson $\beta_2 = \frac{u^4}{u_2^2}$ d'autant plus faible que la courbe est platicurtique.

coefficient de Fisher $\gamma_2 = \beta_2 - 3$

5 Rappels de probabilité

5.1 Notion de base

Expérience aléatoire : on connaît l'ensemble des résultats possible, on ne peut prédire le résultat

Ensemble fondamental Ω de tout les résultats possibles de l'expérience

Événement : résultat , événement vide = \emptyset

exemple : lancer de deux dés successifs

- événement vide \emptyset :somme des deux lancer = 0
- événement certain Ω somme < 13

Opérations

- Négation
- conjonction
- disjonction

Propriétés : Axiome

- $p(\Omega) = 1$.
- $p(\emptyset) = 0$
- $p(!A) = 1 - p(A)$
- $p(A \cup B) = p(A) + p(B)$

Exemple : deux billets pour quatre enfants, 2 filles(b et d), deux garçons (a et c), quelle probabilité de choisir un gars et une fille ?

- événement Ω : on choisit deux personnes a b, a c, a d, b c, b d, c d. Donc chaque couple a une probabilité de $\frac{1}{6}$
- E = a b, a d, b c, b d. donc $\frac{4}{6}$

probabilités conditionnelles probabilité de B sachant A

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

Théorème de Bayes $P(B|A).P(A) = P(A|B).P(B)$

Exemple concret classification supervisée

Utilisation du classifieur bayésien.

Il nous dit que les données sont décrites par des attributs A_1, A_2, \dots, A_n .

Et sont étiquetées par leur classe.

Étant donnée une observation $A_1 = v_1, A_2 = v_2, \dots, A_n = v_n$

déterminer la classe.

$$\begin{aligned} \operatorname{argmax}_{C \in \text{Classes}} P(C|A_1 = v_1, A_2 = v_2, \dots, A_n = v_n) &= \\ \operatorname{argmax}_{C \in \text{Classes}} \frac{P(A_1=v_1, A_2=v_2, \dots, A_n=v_n|C) * P_r(C)}{P(A_1=v_1, A_2=v_2, \dots, A_n=v_n)} &= \\ = \operatorname{argmax}_{C \in \text{Classes}} P(A_1 = v_1, A_2 = v_2, \dots, A_n = v_n|C) * P_r(C) \end{aligned}$$

2 classes, 2 attributs A_1, A_2 qui ont 2 valeurs

$2 + 4 * 2 = 10$ probabilités à calculer, c'est beaucoup

Hypothèse : attributs indépendants/à la classe

$$P(A_1 = v_1, A_2 = v_2, \dots, A_n = v_n|C) = P(A_1 = v_1|C) * \dots * P(A_n = v_n|C)$$

Indépendance $P(A \cap B) = P(A) * P(B)$

Indépendance/à la classe $P(A \cap B|C) = P(A|C) * P(B|C)$

5.2 20 Février 2013

On rappelle que l'ensemble Ω est l'ensemble des événements.

fonction de répartition $F(x) = P(X \leq x)$

- F est croissante
- $\forall x, F(x) \in [0, 1]$

Formule Espérance : $E(X) = \sum x_i p(x_i)$

$$\text{Variance } \sigma^2 = \text{Var}(X) = \sum (x_i - \mu)^2 \cdot p(x_i) = E(X - \mu)^2$$

Propriété de l'espérance et de la variance

- $E(a.X + b) = a.E(X) + b$
- si X et Y sont indépendants : $E(X.Y) = E(X).E(Y)$
- $\text{Var}(a.X+b) = a^2.\text{Var}(X)$

loi conjointe , loi marginale X : nombre de piles, Y : nombre de pile dans les deux premiers essais. On considère donc les probabilités d'avoir les événements X et Y, à savoir quel(s) événement(s) satisfont Y et X. si x et y sont indépendants $p(x, y) = p(x) * p(y)$. la covariance de deux ev indep est 0 , donc on calcule souvent cette donnée sur nos observations pour savoir si des ev sont

indépendants.

$$E(X) = 0 * \frac{1}{8} + 1 * \frac{3}{8} + 2 * \frac{3}{8} + 3 * \frac{1}{8} = 12/8 = 3/2$$

$$E(Y) = 0 * \frac{2}{8} + 1 * \frac{4}{8} + 2 * \frac{2}{8} = \frac{8}{8} = 1$$

loi binomiale : somme d'une série de Bernoulli (ensemble d'ev suivant la même loi)

Probabilité d'avoir x succès sur n tirage : $P(X = x) = C_n^x * p^x * q^{n-x}$ avec $C_n^x = \frac{n!}{x!(n-x)!}$

$\mu = n * p$ (somme de n variables de Bernoulli indépendantes)

$$\sigma^2 = n * p * q$$

Exemple avec R

rXXXX : génération de nombres aléatoires suivant la loi XXXX

dXXXX étant donné un ensemble de valeurs, retourne la hauteur de la probabilité de distribution à chaque point.

pXXXX : probabilité $P(x \leq x)$ qu'un nombre tiré aléatoirement suivant cette loi soit inférieur à un nombre x donné.

qXXXX : nombre X tel que $P(X \leq x)$ soit égale à n , qui est donné.

5.3 Variable aléatoire continue

Machine avec 24 composants

probabilité qu'un composant tombe en panne : 0.2

la machine fonctionne quand au moins deux tiers des composants sont en marche.

Probabilité que la machine fonctionne.

X nombre de composants en marche.

$$P(X \geq 16) = \sum_{i=16}^{24} P(X = i) = \sum_{i=16}^{24} C_{24}^i (0.8)^i (0.2)^{24-i}$$

6 6 Mars 2013

fonction de densité densité f de la variable aléatoire X de fonction de répartition F, c'est la dérivée de la fonction de répartition.

Propriété : $P(a \leq X \leq b) = \int_a^b f(x)dx$. pour Espérance et variance, on utilise la fonction de densité sur un intervalle I

$$E : \int_I x.f(x)dx = \int_0^{360} \frac{x}{360}dx$$

$$\frac{1}{360} \int_0^{360} xdx$$

$$\frac{1}{360} [\frac{x^2}{2}]_0^{360}$$

$$\text{Var} = \int_0^{360} (x - \frac{1}{180})^2 \cdot \frac{1}{360} dx$$

loi uniforme loi uniforme sur intervalle $[a, b]$, densité $f(x) = \frac{1}{b-a}$.
 $F(x) = \int_a^x \frac{dx}{b-a} = \frac{x-a}{b-a}$, pour $a \leq x \leq b$

loi normale Soit X une variable aléatoire à valeur réelles. la loi normale est définie par 2 paramètres, l'espérance μ et la variance σ^2 , notée $X \sim N(\mu, \sigma^2)$

Loi binomiale loi binomiale de paramètre (probabilité) p de taille (nombre de lancers) n .

$$E(X) = n * p$$

$$Var(X) = n * p * (1 - p).$$

2 expériences

- n fixé, faire varier p
- p fixé, on fait croître n .

On considère $Z = \frac{X - np}{\sqrt{n(1-p)}}$. Lorsque n tend vers l'infini, loi binomiale tend vers $N(0, 1)$ (la loi normale centrée).

-> Cas particulier du théorème central limite. Soient X_1, \dots, X_n suite de V.A indépendantes de loi de moyenne μ et de variance σ^2 .

Soit \bar{X}_n la moyenne arithmétique de X_1, \dots, X_n

$$\text{alors } E(\bar{X}_n) = \mu, \text{ } Var(\bar{X}_n) = \frac{\sigma^2}{n}$$

$$Z_n = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \text{ tend vers } N(0, 1) \text{ quand } n \rightarrow \infty$$

7 13 Mars 2013

A savoir connaître loi jointe de deux variables, connaître les rappels de statistiques, un peu de dev R, un peu d'analyse de données. Contrôle lundi après midi

Analyse de régression et corrélation analyse : recherche d'une relation stochastique qui lie 2 ou plusieurs variables. Corrélation : indice mesurant l'intensité de la relation entre 2 variables.

7.1 Analyse de régression

Estimer la valeur d'une des variables à l'aide des valeurs des autres. $Y = f(X)$ avec Y : variable expliquée et X variable explicative.

déterminer le modèle, c'est à dire l'équation de $f(x)$ qui relie X et Y .

estimer le degré de fiabilité de l'estimation.

régression linéaire Entrées : 2 variables X et Y, Sortie : si Y est une fonction de X, notée : $Y = f(X)$.

généralement en premier on regarde le diagramme de dispersion de Y et X, c'est à dire tracer les points d abscisse X et d'ordonnée Y, pour voir si cela suit une fonction linéaire, avec $\text{plot}(X,Y)$, si on constate $Y=aX+b$.

On s'intéresse au cas où l'influence d'une variable sur une autre peut être représentée par une droite de régression.

premier Cas : $Y_i = a + bX_i$. relation déterministe peu probable.

Second cas : $Y_i = a + bX_i + \epsilon_i$ où ϵ_i est un terme d'erreur qui prend en compte les influences aléatoire sur Y.

On cherche un modèle (d'ordre 1) $Y_i = a + bX_i + \epsilon_i$. les inconnues sont a,b, ϵ_i . On cherche à estimer a et b à partir des observations $(X_1Y_1), \dots, (X_nY_n)$ de manière à minimiser les erreurs $\epsilon_i, \forall i$.

on pose $D = \sum \epsilon_i^2 = \sum (Y_i - a - bX_i)^2$. on peut choisir de minimiser $\sum |\epsilon_i|$ au lieu du carré ou minimiser le max des epsilon.

On veut trouver \hat{a} et \hat{b} , qui sont $\text{argmin}_{a,b} D = \sum \text{argmin}(Y_i - a - bX_i)^2$.

\hat{a} , \hat{b} vérifient $\frac{\partial D}{\partial a} = 0$ et $\frac{\partial D}{\partial b} = 0$.

$$\frac{\partial D}{\partial a} = 0 \Leftrightarrow (f(x)^2)' = 2f(x)f'(x) \Leftrightarrow \sum 2(Y_i - \hat{a} - \hat{b}X_i)(-1) = 0 \Leftrightarrow \sum Y_i - n\hat{a} - \hat{b}\sum X_i = 0 \quad (1)$$

$$\frac{\partial D}{\partial b} = 0 \Leftrightarrow (f(x)^2)' = 2f(x)f'(x) \Leftrightarrow \sum 2(Y_i - \hat{a} - \hat{b}X_i)(-X_i) = 0 \Leftrightarrow \sum Y_i X_i - n\hat{a}\sum X_i - \hat{b}\sum X_i^2 = 0. \quad (2)$$

$$\bar{Y} = \frac{\sum Y_i}{n}, \bar{X} = \frac{\sum X_i}{n}.$$

(1) s'écrit $\bar{Y} - \hat{a} - \hat{b}\bar{X} = 0$.

$$\bar{Y} = \hat{a} + \hat{b}\bar{X} \Rightarrow \hat{a} = \bar{Y} - \hat{b}\bar{X}.$$

on remplace \hat{a} par $\bar{Y} - \hat{b}\bar{X}$ dans 2).

$$\text{On trouve } \hat{b} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sum X_i^2 - n\bar{X}^2} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} = \frac{\text{Covar}(X,Y)}{\text{Var}(X)}.$$

X=année	Y=inclinaison
1975	624
1976	644
1977	656
1978	667

sous R $\text{lm}(Y \sim X)$. on doit calculer en premier \bar{X} et \bar{Y} , ensuite \hat{b} à partir de la formule $\hat{b} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sum X_i^2 - n\bar{X}^2} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} = \frac{\text{Covar}(X,Y)}{\text{Var}(X)}$ et ensuite \hat{a} .

Evaluation de la droite de régression estimée Calcul de l'écart entre la valeur observée et la valeur prédite.

$\sum(Y_i - \bar{Y})^2 = \sum(Y_i - \hat{Y}_i)^2 + \sum(\hat{Y}_i - \bar{Y})^2$. On appelle cela la variation totale : $SC_{totale} =$ Variation inexpliquée (somme des carrés des résidus) + variation expliquée (somme des carrés de la régression).

Coefficient de détermination $R^2 = \frac{Variation\ expliquée}{Variation\ totale}$